

Diszkrét matematika 2

10. előadás Kódelmélet

Mérai László

`merai@inf.elte.hu`

`https://sites.google.com/view/laszlomerai`

Komputeralgebra Tanszék

2023 ősz

Forráskódolás

Emlékeztető

Kódolás: $\varphi : \mathcal{X} \rightarrow \mathcal{Y}^*$ **injektív** függvény. Szavak kódolása **betűnként**:
 $\varphi(u_1 u_2 \dots u_r) = \varphi(u_1) \varphi(u_2) \dots \varphi(u_r)$

Felbontható kódolás: ha egyértelműen dekódolható: $\mathbf{u} \neq \mathbf{v}$, akkor

$$\varphi(u_1) \varphi(u_2) \dots \varphi(u_r) \neq \varphi(v_1) \varphi(v_2) \dots \varphi(v_s).$$

Prefix kódolás

Célunk **elégséges** feltételt adni a **felbonthatóságra**.

Definíció

Egy $u = abc$ szó

- **prefixe**: a , ab , abc ;
- **infixe**: b , ab , bc : abc ;
- **szuffixe**: c , bc , abc .

Definíció

Egy φ kódolás **prefix kód** (vagy **prefixmentes kód**), ha nem léteznek olyan u, v különböző kódszavak, hogy u **prefixe** v -nek.

Példa

- ASCII és UTF-8 **prefix kódok**.
- Morze-kód **nem** prefix kód:
 $\varphi(e) = \cdot$ és $\varphi(i) = \cdot\cdot$ prefixei a $\varphi(s) = \cdot\cdot\cdot$ kódszónak.

Prefix kódolás

Prefix kód: **nincsenek** olyan **u, v** kódszavak, hogy **u = vc** valamely **c** szóra.

Tétel

Minden prefix kód felbontható.

Bizonyítás.

- Legyen $\mathbf{v} = v_1 v_2 \dots v_s \in \mathcal{Y}^*$ egy üzenet **kódolása**. (Azaz létezik olyan **u**, hogy $\varphi(\mathbf{u}) = \mathbf{v}$.)
- Vizsgáljuk meg a prefixeit:
 - v_1
 - $v_1 v_2$
 - $v_1 v_2 v_3$
 - \dots
- Ha találunk egy $v_1 v_2 \dots v_i$ szót, ami egy betű kódszava, azt dekódolhatjuk. Mivel a kód **prefix**, ez nem lehet más betű kódjának prefixe.
- Az eljárást folytathatjuk a $v_{i+1} v_{i+2} \dots v_s$ kóddal.

Kódfa


Definíció

Egy φ kód **kódfája** egy olyan fa, melynek csúcsai a **kódszavak** és azok **prefixei** és az $y_1y_2 \dots y_s$ és $y_1y_2 \dots y_sy_{s+1}$ csúcsok vannak összekötve.


Állítás: Egy kód **prefix**, ha csak a levelek a kódszavak.

Példa

A $\{0, 100, 101, 111\}$ kódszóhal-
maz kódfája:



A $\{00, 01, 110, 111\}$ kódszóhal-
maz kódfája:



Prefix kódolás

Prefix kód: **nincsenek** olyan u, v kódszavak, hogy $u = vc$ valamely c szóra.

Példa

- A $\{0, 100, 101, 111\}$ kód **prefix**.
- A $\{100, 10, 11\}$ kód **nem** prefix: $10, 100$ szavak is kódszavak.

Elégséges feltételek a **prefix** tulajdonságra:

Definíció

Legyen $\mathcal{C} \subset \mathcal{Y}^*$ a kódszavak véges halmaza. Ekkor

- A \mathcal{C} kód **egyenletes** (blokk kód), ha minden $c \in \mathcal{C}$ kódszó azonos hosszú.
- A \mathcal{C} kód **vesszős kód**, ha van olyan $v \in \mathcal{Y}^*$ nemüres szó („vessző”), mely **szuffixe** minden $c \in \mathcal{C}$ kódszónak, de **nem** valódi prefixe, ill. infixe semelyik kódszónak. (Azaz $c = uv$ valamely $u \in \mathcal{Y}^*$ szóra, de $c \neq uvz$ valamely $u, z \in \mathcal{Y}^*, z \neq \emptyset$.)


Példa

- A $\{000, 010, 111, 101\}$ kód **egyenletes**.
- A $\{0100, 100, 1100\}$ kód **vesszős**.

Felbontható kód mégegyszer

Tétel (Biz. HF.)

Minden **egyenletes** ill. **vesszős** kód prefix.



Példák

Példa


- ASCII: **egyenletes kód**: minden karakter 7 biten kódolt.
- UTF-8: **prefix kód**:

0xxxxxxx	ASCII karakterek
110yyyyy 10xxxxxx	nem ASCII karakterek
1110zzzz 10xxxxxx 10yyyyyy	
11110www 10zzzzzz 10xxxxxx 10yyyyyy	

- Ha az első karakter 0 → ASCII karakter
- Ha az első karakter 1 → nem ASCII karakter. Ekkor a kódszó több byte, első blokk 1-ek száma a byte-ok száma, 1-ek után 0, minden további byte 10-val kezdődik.

Csatornakódolás

Csatornakódolás



Hiba fajták

- karakter módosulás
- karakterek törlése
- karakterbeszúrás

Lehetséges módszerek

- hibajelzés
- hibajavítás

Példák kódokra

- **Kódisméltés:** $0 \mapsto 000, 1 \mapsto 111$
Képes **egy** hibát javítani, **két** hibát jelezni
- **ISBN** (könyvek és egyéb kiadványok egyedi azonosítója).
Az **első típus** (10 számjegyű, 2007-ig).
Ha I_1, I_2, \dots, I_{10} az ISBN, akkor ez helyes, ha

$$1 \cdot I_1 + 2 \cdot I_2 + \dots + 10 \cdot I_{10} \equiv 0 \pmod{11}.$$

Példa ISBN 0-246-024682

$$1 \cdot 0 + 2 \cdot 2 + 3 \cdot 4 + 4 \cdot 6 + 5 \cdot 0 + 6 \cdot 2 + 7 \cdot 4 + 8 \cdot 6 + 9 \cdot 8 + 10 \cdot 0 = 220 \equiv 0 \pmod{11}$$

Képes egy hibát ill. két szomszédos számjegy felcserélését jelezni.

- **Paritásbit** Legyen $\mathbf{u} \in \{0, 1\}^k$. $\mathbf{u} \mapsto (u_1, \dots, u_k, u_1 + u_2 + \dots + u_k \pmod{2})$.
Képes egy hibát jelezni.

Kódszavak, Hamming-távolság

Mostantól **karakter módosulás** típusú hibákra fókuszálunk!

Definíció

Legyen Σ egy véges halmaz (ábécé) és tekintsük az n hosszú szavak halmazát Σ^n . Ekkor a $\mathcal{C} \subset \Sigma^n$ részhalmaz egy **kód**, elemei a **kódszavak**.

Tipikusan $\Sigma = \mathbb{F}_2$ vagy általában \mathbb{F}_{2^k} .

Definíció

Legyen $\mathbf{u}, \mathbf{v} \in \Sigma^n$ két szó. A szavak **Hamming-távolsága**: $d(\mathbf{u}, \mathbf{v}) = \#\{i : u_i \neq v_i\}$.

Példa

- $d(000, 111) = 3$, $d(012, 210) = 2$
- $d(0000, 0001) = 1$, $d(0000, 0009) = 1$, $d(1234, 0123) = 4$
- általában: $0 \leq d(\mathbf{u}, \mathbf{v}) \leq n$

Hamming távolság

Hamming-távolság:

Legyen $\mathbf{u}, \mathbf{v} \in \Sigma^n$ két szó. A szavak **Hamming-távolsága**: $d(\mathbf{u}, \mathbf{v}) = \#\{i : u_i \neq v_i\}$.

A Hamming-távolság d valóban egy távolság-függvény:

Tétel

Legyen $d : \Sigma^n \times \Sigma^n \rightarrow \{0, 1, 2, \dots\}$ a Hamming-távolság. Ekkor

- $d(\mathbf{u}, \mathbf{v}) = 0 \iff \mathbf{u} = \mathbf{v}$.
- $d(\mathbf{u}, \mathbf{v}) = d(\mathbf{v}, \mathbf{u})$.
- $d(\mathbf{u}, \mathbf{v}) \leq d(\mathbf{u}, \mathbf{c}) + d(\mathbf{c}, \mathbf{v})$ (háromszög egyenlőtlenség).

Hamming távolság

Tétel:

- $d(\mathbf{u}, \mathbf{v}) = 0 \iff \mathbf{u} = \mathbf{v}$.
- $d(\mathbf{u}, \mathbf{v}) = d(\mathbf{v}, \mathbf{u})$.
- $d(\mathbf{u}, \mathbf{v}) \leq d(\mathbf{u}, \mathbf{c}) + d(\mathbf{c}, \mathbf{v})$ (háromszög egyenlőtlenség).

Bizonyítás.

Az **első két tulajdonság** közvetlenül adódik a definícióból.

Háromszög egyenlőtlenség: a bizonyítás koordinátánként.

Terjesszük ki a d függvényt a **koordinátákra**: $u, v \in \Sigma$ esetén $d(u, v) = 0$ ha $u = v$ és $d(u, v) = 1$ ha $u \neq v$.

Ekkor $d(\mathbf{u}, \mathbf{v}) = \sum_i d(u_i, v_i)$. Adott i -re,

- ha $u_i = v_i$, akkor $0 = d(u_i, v_i) \leq d(u_i, c_i) + d(c_i, v_i)$;
- ha $u_i \neq v_i$, akkor $c_i \neq u_i$ vagy $c_i \neq v_i$. Így $d(u_i, c_i) + d(c_i, v_i) \geq 1 = d(u_i, v_i)$.

Kódtávolság

Definíció

Egy \mathcal{C} kód **kódtávolsága** a kódszavak közti minimális távolság: $d(\mathcal{C}) = \min\{d(\mathbf{u}, \mathbf{v}) : \mathbf{u}, \mathbf{v} \in \mathcal{C}, \mathbf{u} \neq \mathbf{v}\}$.

Példa

- Az **ismétlő kód** ($0 \mapsto 000, 1 \mapsto 111$) távolsága $d = 3$.
- **Paritásbit** ($\mathbf{u} \mapsto (u_1, \dots, u_k, u_1 + u_2 + \dots + u_k \bmod 2)$) távolsága $d = 2$.

Tétel (Biz.: HF)

Egy \mathcal{C} kód $d = d(\mathcal{C})$ kódtávolsággal:

- $d - 1$ hibát tud **jelezni**;
- $t = \lfloor (d - 1)/2 \rfloor$ hibát tud **javítani**.

